UNIVERSIDAD POLITÉCNICA DE ATLAUTLA

ACTIVIDAD PARCIAL 2

2.3 BÚSQUEDA LOCAL: HILL CLIMBING Y SIMULATED ANNEALING

Optimización ilustrativa de una ruta de reparto

Asignatura	Fundamentos de Inteligencia Artificial
Programa	Ingeniería en Tecnologías de la Información e Innovación Digital
Estudiante	Luis Antonio Roman Rey
Grupos / cuatrimestre	171 y 172 / Séptimo
Docente	Mtro. Javier García Lara
Entrega	22 de octubre de 2026

Reporte técnico con formulación del problema, procedimiento, implementación en Python, gráfica de convergencia y comparación de resultados.

1. Planteamiento del problema

Una pequeña empresa de reparto necesita visitar ocho ubicaciones y regresar al punto de salida. El orden de visita afecta la distancia total recorrida. Se busca reducir el costo de la ruta mediante dos métodos de búsqueda local: Hill Climbing (ascenso de colinas, adaptado a minimización) y Simulated Annealing (recocido simulado).

Para que el experimento sea reproducible sin depender de servicios de mapas, se utilizan coordenadas cartesianas sintéticas. Por ello, las distancias son kilómetros ilustrativos y no representan mediciones reales de calles.

Objetivo general

Implementar y comparar ambos algoritmos para minimizar la distancia de una ruta cerrada, analizando función objetivo, vecindad, parámetros y convergencia.

2. Datos del problema

Ubicación	x	y
Centro	0	0
Norte	2	6
Mercado	3	2
Hospital	6	5
Escuela	7	1
Parque	1	4
Bodega	5	7
Sur	4	-2

Centro es el origen y final de la ruta; cada una de las otras siete ubicaciones se visita una sola vez.

3. Formulación del problema

Estado: una ruta ordenada que inicia en Centro y visita cada ubicación una vez.
Estado inicial: una permutación aleatoria reproducible.
Acciones: intercambiar dos ubicaciones que no sean el origen.
Transición: la ruta resultante del intercambio.
Meta: encontrar una ruta de costo mínimo o mejorar el costo dentro del límite de iteraciones.
Costo: suma de las distancias entre ubicaciones consecutivas, incluido el regreso al origen.

Distancia euclidiana: $d(A,B) = \sqrt{[(xA - xB)^2 + (yA - yB)^2]}$.

Función objetivo: minimizar $f(ruta) = \Sigma\, d(ruta[i], ruta[i+1])$, incluyendo el tramo final de regreso a Centro.

4. Procedimiento

4.1 Hill Climbing

Parte de una ruta inicial y genera un vecino por intercambio de dos paradas. Si el vecino reduce el costo, lo acepta; de lo contrario, conserva la ruta actual. Es sencillo, pero puede quedarse en un óptimo local porque no acepta movimientos temporalmente peores.

4.2 Simulated Annealing

También genera vecinos por intercambio. Acepta siempre una mejora y puede aceptar una solución peor con probabilidad $\exp(-\Delta/T)$, donde Δ es el aumento del costo y T la temperatura. La temperatura disminuye con las iteraciones, reduciendo progresivamente la aceptación de empeoramientos.

5. Parámetros experimentales

Parámetro	Valor	Justificación
Iteraciones	500 por algoritmo	Mismo presupuesto para ambos métodos.
Semilla aleatoria	42	Reproducibilidad del experimento.
Temperatura inicial T■	20.0	Facilita explorar al comienzo.
Enfriamiento α	0.995	Actualización $T \leftarrow \alpha T$.
Vecindad	Intercambiar 2 paradas	Conserva todas las ubicaciones.

6. Implementación y resultados

El archivo FIA_2.3_Busqueda_Local_Luis_Roman.py implementa los dos algoritmos y registra el mejor costo en cada iteración. Con 500 iteraciones y semilla 42, la ejecución de referencia produjo los siguientes resultados:

Método	Ruta obtenida	Costo
Hill Climbing	Centro → Parque → Norte → Bodega → Hospital → Escuela → Sur → Mercado → Centro	27.85 km
Simulated Annealing	Centro → Mercado → Sur → Escuela → Hospital → Bodega → Norte → Parque → Centro	27.85 km

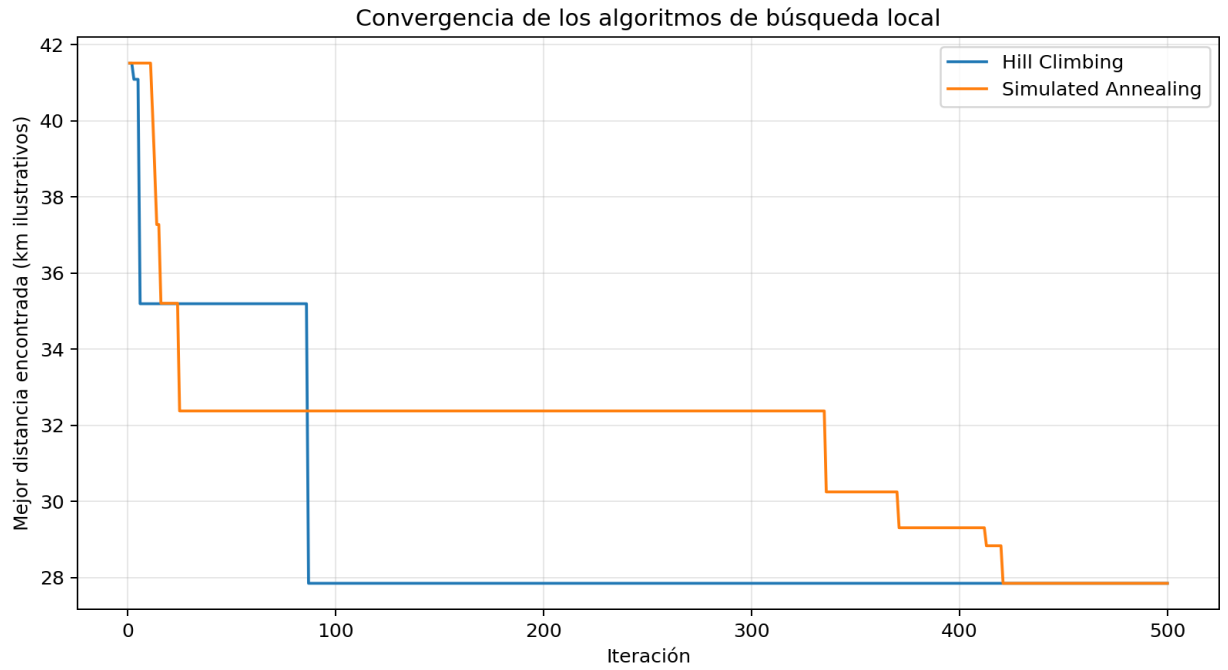


Figura 1. Convergencia del mejor costo encontrado por iteración. La gráfica se vuelve a generar al ejecutar el programa. Los datos son sintéticos y las distancias son ilustrativas.

Interpretación de resultados

En esta ejecución ambos métodos alcanzaron costos prácticamente iguales. Esto no significa que siempre tengan el mismo rendimiento; el resultado depende de la ruta inicial, la vecindad y los parámetros.

7. Comparación técnica

Criterio	Hill Climbing	Simulated Annealing
Aceptación	Solo acepta mejoras.	Acepta mejoras y algunos empeoramientos.
Ventaja	Simple y rápido.	Puede escapar de óptimos locales.
Limitación	Puede atascarse en un óptimo local.	Depende de la temperatura y del enfriamiento.
Uso	Mejora rápida en vecindades sencillas.	Problemas con muchos óptimos locales.

8. Complejidad y limitaciones

Con n ubicaciones, evaluar el costo de una ruta requiere O(n). Cada iteración crea un vecino y evalúa su costo; por ello, el tiempo aproximado es O(I·n), donde I representa las iteraciones. El almacenamiento de la ruta es O(n); el historial de convergencia ocupa O(I).

La comparación no demuestra optimalidad global: utiliza una sola semilla y un conjunto sintético. Para una evaluación más robusta se podrían realizar varias corridas y comparar promedios, mejores costos y dispersión. La distancia euclidiana tampoco modela calles, sentidos de circulación ni tráfico.

9. Conclusiones

La actividad permitió formular una ruta de reparto como problema de búsqueda local y comparar dos estrategias. Hill Climbing es fácil de implementar, pero puede quedarse en una solución local al rechazar cualquier empeoramiento. Simulated Annealing introduce una probabilidad de aceptar empeoramientos controlada por la temperatura, lo que favorece la exploración al inicio y la búsqueda de mejoras al final. La calidad depende de la vecindad, los parámetros y los datos. El código permite reproducir el experimento y observar la convergencia; los resultados deben entenderse como ilustrativos, no como una ruta real verificada.

10. Declaración de uso de inteligencia artificial

Herramienta: ChatGPT (OpenAI).
Propósito/prompt: apoyo para organizar el reporte, explicar los algoritmos de búsqueda local y preparar un ejemplo de implementación en Python que compare Hill Climbing y Simulated Annealing.
Verificación: antes de entregar, ejecutar el código en el equipo del estudiante, revisar las rutas y costos impresos, comprobar la gráfica y contrastar las explicaciones con las fuentes. El estudiante debe comprender el código y poder explicar sus decisiones.

11. Referencias (APA 7)

Kirkpatrick, S., Gelatt, C. D., Jr., & Vecchi, M. P. (1983). Optimization by simulated annealing. *Science, 220*(4598), 671–680. https://doi.org/10.1126/science.220.4598.671

Russell, S. J., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4th ed.). Pearson.

Python Software Foundation. (s. f.). *Python 3 documentation*. https://docs.python.org/3/

Matplotlib Development Team. (s. f.). *Matplotlib documentation*. https://matplotlib.org/stable/

Anexo. Archivo de código

Subir junto con este PDF el archivo FIA_2.3_Busqueda_Local_Luis_Roman.py. Al ejecutarlo, debe imprimir las rutas y costos y guardar la gráfica FIA_2.3_grafica_convergencia.png.